Ejercicio 07 · Evaluación de impacto y auditoría de equidad

INF-8239 Ciencia de Datos II (UASD) · Unidad 04 · Integración de LAB11 y LAB12

Estudiante	Edwing Perez
Profesor	Edwin Ramón José Nolasco
Repositorio	https://github.com/edvvdev/unidad04-07
Caso	Riesgo territorial SINTÉTICO (640 registros) · no representa personas ni estadísticas reales de RD
Decisión	LIMITAR · piloto en modo REVIEW con puerta de equidad trimestral y condiciones de retiro

1. Finalidad, interesados y proporcionalidad

Priorizar la revisión humana de casos con señal de riesgo territorial para orientar el esfuerzo de prevención (verificación en campo y acompañamiento). El sistema no decide: ordena la cola de revisión y aporta evidencia. El caso de negocio es didactic and synthetic: el dataset incluido es un caso territorial sintético que no representa personas, territorios ni estadísticas reales de República Dominicana.

Reparto rotativo por zona y severidad reportada, priorización manual de todas las alertas recibidas, o inversión en infraestructura y tiempo comunitario priorizado por criterios publicados y no por un modelo. Estas alternativas no usan datos individuales y por tanto evitan la exposición a datos sensibles.

Prohibido: Prohibido usar el modelo o su ranking para: decidir sanciones, sanciones administrativas o prohibiciones de cualquier tipo; abrir expedientes o imputar responsabilidades; distribuir fondos o recursos entre zonas según el ranking de riesgo; autorizar identificaciones, registros o vigilancia; puntuar a personas; y usar datos de la cola para entrenar otros sistemas.

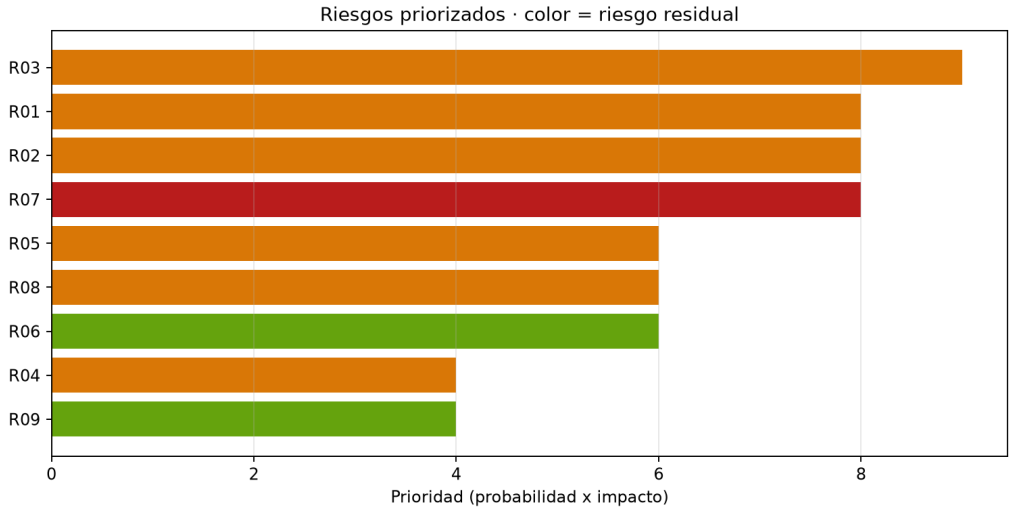
Interesado	Beneficio	Daño posible	Poder	Participación
Affected person	Personas y comunidades que reciben la verificacion: la priorizacion re…	Falsos positivos concentran visitas en una persona o zona sin riesgo; …	low	Canal de apelacion; registro de peticiones y rev…
Operator	Analistas y coordinadores: reciben una cola ordenada y reduces carga d…	Presion para tratar la lista como orden de ejecucion y perder el juici…	medium	Formacion y procedimiento que exige registrar la…
Institutional owner	La direccion del programa: disposicion de la capacidad de verificacion…	Responsabilidad por decisiones tomadas con un sistema que nadie ha aud…	high	Aprobacion explicita de la puesta en marcha; pos…
Data team	Equipo tecnico: aprende del feedback de revision y puede corregir el m…	Model drift por cambio de zona o de tasa de reporte; dependencia de un…	medium	Monitoreo trimestral; reporte de derivas; y obli…

2. Registro de riesgos y NIST AI RMF

Nueve riesgos con control, responsable, evidencia y riesgo residual. La prioridad es probabilidad × impacto: ordena la atención, **no** convierte el daño humano en una verdad matemática. Marco: **NIST AI RMF 1.0** (DOI 10.6028/NIST.AI.100-1) — GOVERN (responsable y política), MAP (riesgos documentados), MEASURE (auditoría del LAB12) y MANAGE (condición de retiro y recurso de apelación).

ID	Escenario (resumen)	L	I	Prioridad	Control (resumen)	Responsable	Residual
R03	Brecha de recall entre grupos: el grupo con menor recall r…	3	3	9	Auditoria de equidad global; por grupo e i…	Responsable de equidad (equipo de …	medium
R01	Falso positivo: la cola prioriza un caso sin señal de ries…	2	4	8	Umbral de priorizacion mas revision humana…	Analista de riesgo responsable de …	medium
R02	Falso negativo: un caso con incidente probable no aparece …	2	4	8	Cola secundaria por severidad reportada co…	Coordinador de operacion…	medium

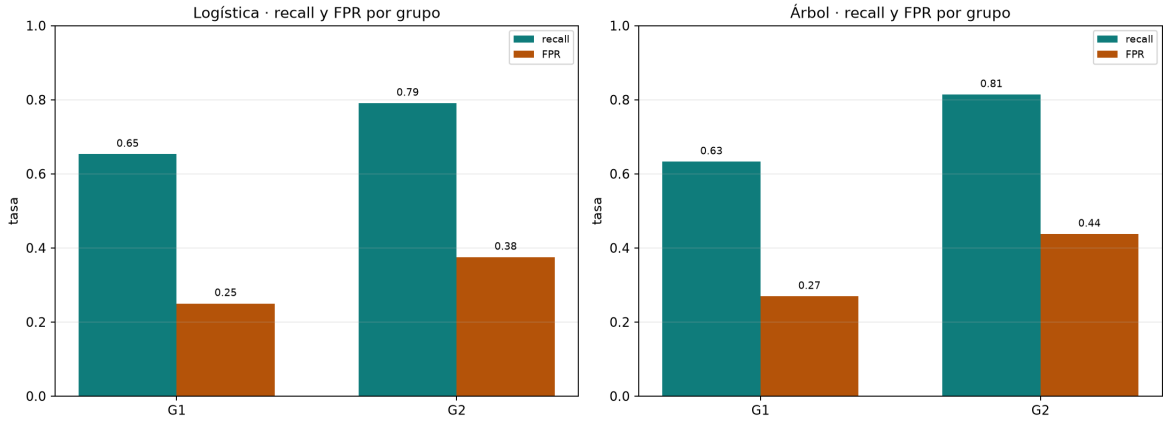
ID	Escenario (resumen)	L	I	Prioridad	Control (resumen)	Responsable	Residual
R07	Presion operativa para que el DSS decida sin revision huma…	2	4	8	Autoridad limitada a REVIEW; firma humana …	Direccion del programa…	high
R05	Reutilizacion del modelo o de la cola priorizada para un f…	2	3	6	Clausula de alcance; revision trimestral d…	Direccion del programa…	medium
R08	El atributo sensible excluido del modelo deja sesgo indire…	2	3	6	Auditoria interseccional de grupo y banda …	Responsable de equidad…	medium
R06	El caso sintetico se interpreta como evidencia sobre zonas…	3	2	6	Etiqueta visible de caso sintetico en la a…	Equipo de datos…	low
R04	Uso indebido del ranking para distribuir fondos o recursos…	1	4	4	Prohibicion explicita en el alcance; claus…	Direccion del programa…	medium
R09	El sistema recibe datos con identificadores directos o dat…	1	4	4	Contrato de datos con columnas prohibidas;…	Equipo de datos…	low



3. Auditoría global, por grupo e interseccional

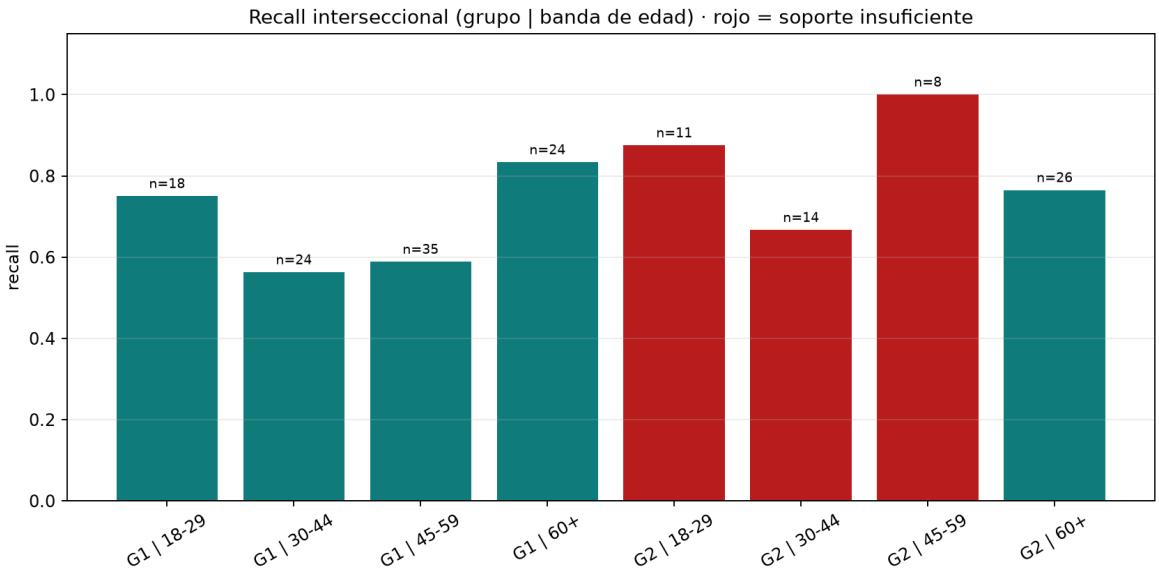
Métrica	Global	G1 (n=101)	G2 (n=59)	Brecha
Accuracy	0.7188	0.7030	0.7458	0.0428
Recall (TPR)	0.7174	0.6531	0.7907	0.1376
FPR	0.2794	0.2500	0.3750	0.1250
Tasa de selección	0.5312	0.4455	0.6780	0.2324
Precisión	0.7765	0.7111	0.8500	0.1389

Tasa base de positivos en la prueba: G1 48,5 % frente a G2 72,9 % (datos completos: 49,7 % y 63,9 %). La diferencia de recall refleja en parte esa prevalencia distinta, no una decisión discriminatoria demostrada: el atributo sensible no entra al modelo. Fuente: reports/lab13/dataset_stats.json.



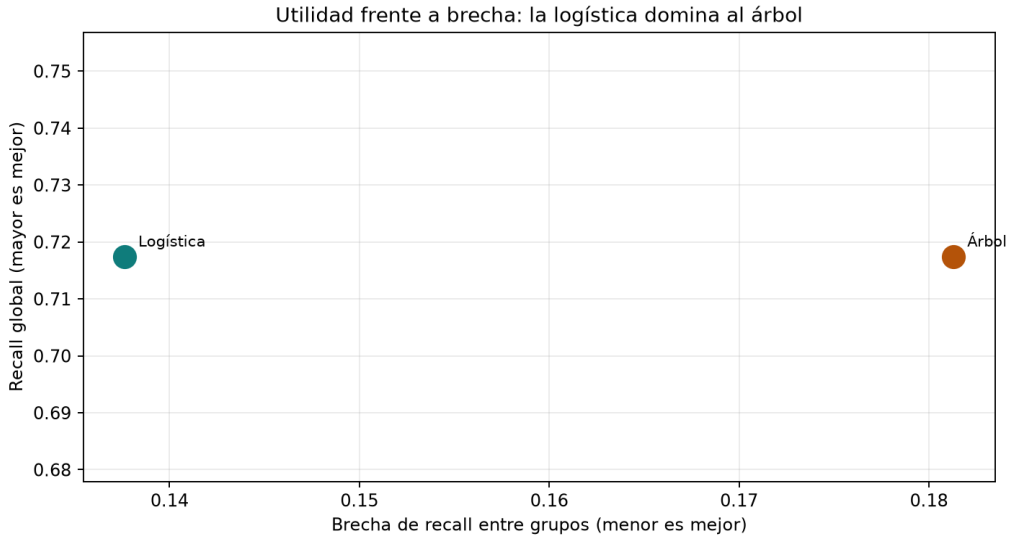
Celdas interseccionales (grupo | banda de edad, modelo logística)

Celda	n	Recall	FPR	Soporte
G1 | 18-29	18	0.7500	0.1429	aceptable
G1 | 30-44	24	0.5625	0.1250	aceptable
G1 | 45-59	35	0.5882	0.3889	aceptable
G1 | 60+	24	0.8333	0.2500	aceptable
G2 | 18-29	11	0.8750	0.0000	INSUFICIENTE
G2 | 30-44	14	0.6667	0.5000	INSUFICIENTE
G2 | 45-59	8	1.0000	0.0000	INSUFICIENTE
G2 | 60+	26	0.7647	0.5556	aceptable


Recall interseccional (grupo | banda de edad) · rojo = soporte insuficiente
recall
0.0
0.2
0.4
0.6
0.8
1.0
n=18
n=24
n=35
n=24
n=11
n=14
n=8
n=26
G1 | 18-29
G1 | 30-44
G1 | 45-59
G1 | 60+
G2 | 18-29
G2 | 30-44
G2 | 45-59
G2 | 60+

4. Mitigación, trade-offs y decisión

Alternativa	Accuracy	Recall	FPR	Brecha recall	Brecha FPR	Entreno (s)	Modelo (KB)
Logística	0.7188	0.7174	0.2794	0.1376	0.1250	0.0165	3.56
Árbol	0.7063	0.7174	0.3088	0.1813	0.1683	0.0128	7.90



El árbol alcanza la **misma utilidad global** (recall 0,7174) con **brechas mayores** (recall 0,1813 frente a 0,1376; FPR 0,1683 frente a 0,1250) y el **doble de tamaño** (7,90 KB frente a 3,56 KB): el costo adicional no se justifica.

Daño priorizado

Falso negativo: que un caso con incidente probable no llegue a la cola priorizada y la atencion preventiva no se vea a tiempo (las personas que debian recibirla quedan sin verificar). En segundo lugar, el falso positivo que desplaza capacidad de campo hacia casos sin riesgo.

Métrica principal

Brecha de recall (TPR) entre grupos, junto al recall absoluto del grupo con peor desempeño. El recall global 0.7174 no basta: en el grupo G1 el recall es 0.653 frente a 0.791 en G2.

Tolerancia y puerta

Decision documentada: LIMITAR (no hay despliegue autonomo; piloto en modo REVIEW con revision humana obligatoria y el baseline sin modelo como camino operativo seguro). Estado del pipeline: REVIEW, porque fallan tres puertas: worst_group_recall (0.6531 < 0.70), recall_gap_pilot (0.1376 > 0.10) e intersectional_support (8 < 15). Tolerancia de equidad: brecha de recall entre grupos <= 0.10 y recall del grupo con peor desempeño >= 0.70. Escalamiento a STOP: si la brecha supera 0.15 o el recall del peor grupo cae por debajo de 0.60, el sistema se retira al baseline sin modelo y se detiene la priorizacion automatica hasta nueva auditoria.

Limitaciones

Caso sintetico de 640 registros que no representa personas ni territorios reales. La brecha de recall refleja en parte la tasa base de positivos (G2 63.9 % frente a G1 49.7 %), no una discriminacion causal demostrada: el atributo sensible no entra al modelo, pero zona y banda de edad pueden portar el mismo sesgo de forma indirecta. El soporte interseccional es insuficiente en varias celdas, hay una sola particion temporal y una sola semilla, y no se calcularon intervalos de confianza; ademas, el limite de decision depende del coste real de un falso negativo, que en este caso sintetico no esta cuantificado.

Recomendación

LIMITAR: no hay despliegue autonomo y no se usa el ranking como orden de ejecucion. Autorizar un piloto en modo REVIEW, con revision humana obligatoria de cada caso, el modelo logistico (mejor que el arbol en brechas y costo) como unica configuracion, el baseline sin modelo como camino operativo seguro, y una puerta de equidad que mida la brecha de recall por grupo en cada revision trimestral. Estado del pipeline: REVIEW, con tres puertas fallidas (worst_group_recall, recall_gap_pilot e intersectional_support) que obligan a una decision humana documentada. Escalamiento a STOP: si la brecha de recall supera 0.15 o el recall del peor grupo baja de 0.60, el sistema se retira al baseline sin modelo. Antes de cualquier uso con datos reales hay que repetir la auditoria con datos de un periodo posterior, con intervalos de confianza y con el coste del dano cuantificado; y mantener como condicion de retiro que exista capacidad de revision humana y que el caso siga siendo sintetico y documentado.

Obligación legal, marco voluntario y recomendación ética. En este caso sintético no hay una obligación legal específica que se pueda verificar (no hay datos personales ni decisiones reales), y esa ausencia se documenta en lugar de suplirse con el marco técnico: el **NIST AI RMF 1.0** (marco voluntario) organiza el control —GOVERN, MAP, MEASURE, MANAGE— y la **recomendación ética** (alternativa no predictiva, recurso de apelación, condición de retiro) sostiene la decisión. Ninguna de las dos sustituye a la revisión jurídica que cualquier uso con datos reales exigiría.

Uso responsable de IA. El asistente de IA (Kilo, modelo MiniMax-M3) apoyó la estructura de los artefactos, la redacción de las tarjetas y la corrección de dos scripts del proyecto base que no compilaban (`lab11_impact.py` y `simulate_incident.py`, por saltos de línea reales dentro de literales). Los **valores del análisis** —finalidad, interesados, probabilidad e impacto de cada riesgo, tolerancia, métrica principal y recomendación— los decidió el estudiante con la evidencia del manual y de las ejecuciones; el asistente no inventó ninguna cifra ni referencia. Detalle en `docs/AI_USE_DECLARATION.md`.

Referencias. NIST, *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*, DOI 10.6028/NIST.AI.100-1 · OECD, *Recommendation of the Council on Artificial Intelligence*, DOI 10.1787/cc2e1d3e-en · Fairlearn Contributors, *Performing a Fairness Assessment* (documentación oficial).