Ejercicio 08 · Expediente de gobernanza y simulacro

INF-8239 Ciencia de Datos II (UASD) · Unidad 04 · Integración de LAB13

Estudiante	Edwing Perez
Profesor	Edwin Ramón José Nolasco
Repositorio	https://github.com/edvvdev/unidad04-08
Caso	Riesgo territorial SINTÉTICO (640 registros) · no representa personas ni estadísticas reales de RD
Decisión final	LIMITAR · DSS en modo REVIEW, revisión humana obligatoria, baseline sin modelo como camino seguro
Decisión del pipeline	REVIEW · puertas fallidas: worst_group_recall, recall_gap_pilot, intersectional_support

1. Inventario, minimización y retención

Todo campo declarado tiene origen, uso, condición de entrada al modelo, plazo de retención y justificación. Las columnas de identificadores directos (`name, document_number, email, phone`) se rechazan **antes** de predecir (`validate_schema`, verificado por `tests/test_privacy.py`).

Campo	Uso	¿Entra al modelo?	Retención (días)	Justificación
case_id	trazabilidad interna del caso sintetico…	no	730	identificador del registro sintetico; no con…
received_date	corte temporal y deteccion de deriva…	no	730	fecha sintetica de recepcion; no se usa como…
zone	variable predictora…	sí	365	contexto territorial sintetico, disponible a…
age_band	variable predictora y auditoria intersecci…	sí	365	banda de edad sintetica, disponible al prede…
previous_incidents	variable predictora…	sí	365	historial de incidentes reportados…
infrastructure_score	variable predictora…	sí	365	indice sintetico de infraestructura…
exposure	variable predictora…	sí	365	exposicion sintetica al evento…
protected_group	auditoria de equidad por grupo; nunca entr	no	365	atributo sensible conservado solo para audit…
target	etiqueta para entrenamiento y evaluacion…	no	730	etiqueta sintetica…

Minimización: `case_id`, `received_date`, `protected_group` y `target` quedan fuera del modelo por decisión explícita. Retención de artefactos: registros operativos 180 días, logs de revisión 365, modelos y reportes 730, registros de apelación 1.095; la supresión la ejecuta el Data Engineer con aprobación del Legal and Data Protection Officer.

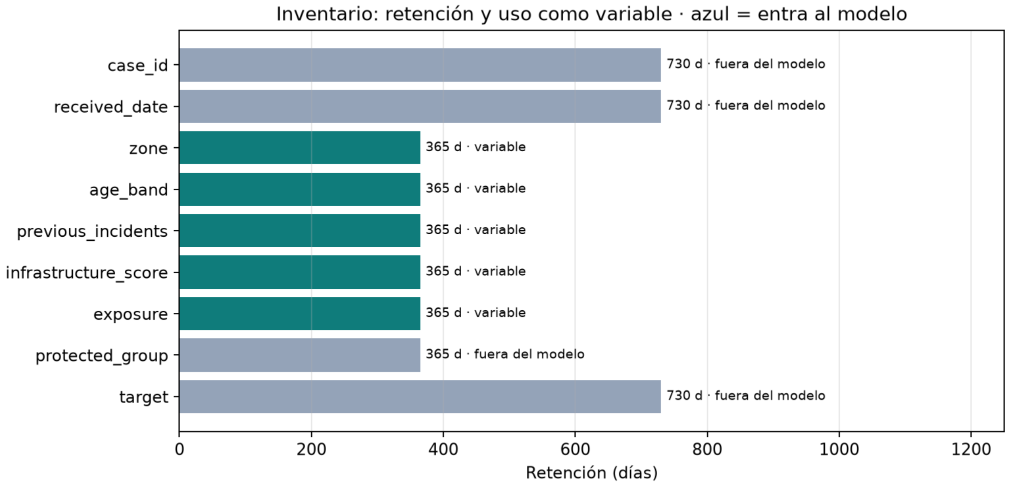

2. Datasheet y Model Card trazables

Documento	Contenido	Evidencia que respalda cada cifra
docs/DATASET_CARD.md	Procedencia, diccionario, auditoría, sesgos, usos prohibidos	reports/audit_summary.json · reports/lab12/*
docs/MODEL_CARD.md	Uso previsto y fuera de alcance, datos y partición, evaluación por subgrupo, Green AI, puertas, límites, apelación, propietario	reports/lab13/deployment_decision.json · reports/lab12/*
docs/INVENTARIO_Y_RETENCION.md	Inventario por campo, minimización, retención y supresión, trazabilidad	configs/governance.yaml · tests/test_privacy.py · tests/test_governa
docs/RUNBOOK.md	Detección, autoridad de contención, preservación de evidencia, comunicación, rollback y postmortem	reports/lab13/INCIDENT_POSTMORTEM.md
reports/lab11/DECISION_RECORD.md	Evaluación de impacto, tres riesgos prioritarios, incertidumbre, responsables y condiciones de retiro	reports/lab11/risk_register.csv · rmf_summary.json
student_inputs/lab12_decision.yml	Daño priorizado, métrica principal, tolerancia, evidencia, limitación y documentación	reports/lab12/* · reports/lab12/tree/*

3. RACI y traspaso entre roles

Cada actividad tiene **un solo responsable final (A)** y al menos un responsable de ejecución (R); el traspaso es explícito porque quien entrega un artefacto lo entrega a un rol que puede rechazarlo. Verificación automática: `validate_raci` falla si una actividad no tiene A o R.

Actividad	R (ejecuta)	A (responde)	C (consulta)	I (informado)
Data quality and data contract	Data Engineer	Product Owner	Data Scientist	Affected representatives
Privacy review and prohibited columns	Data Engineer	Legal and Data Protection	Data Scientist	Affected representatives
Model validation and reproducibility	Data Scientist	Product Owner	Data Engineer	Users
Fairness audit (global, group and intersecti	Data Scientist	Responsible for Equity	Legal and Data Protectio	Affected representatives
Impact assessment and alternative comparison	Data Scientist	Institutional Owner	Responsible for Equity	Affected representatives
Deployment approval of the governed DSS	ML Engineer	Product Owner	Data Scientist	Users
Daily operation and human review of the queu	Operations Analyst	Product Owner	ML Engineer	Affected representatives
Monitoring, drift review and quarterly repor	ML Engineer	Institutional Owner	Data Scientist	Users
Incident detection, containment and rollback	ML Engineer	Institutional Owner	Legal and Data Protectio	Affected representatives
Appeal handling of affected persons	Responsible for Equity	Institutional Owner	Operations Analyst	Affected representatives
Retention, deletion and expiry of evidence	Data Engineer	Legal and Data Protection	Data Scientist	Affected representatives
Model revision, retirement or decommissionin	Data Scientist	Institutional Owner	Product Owner	Users

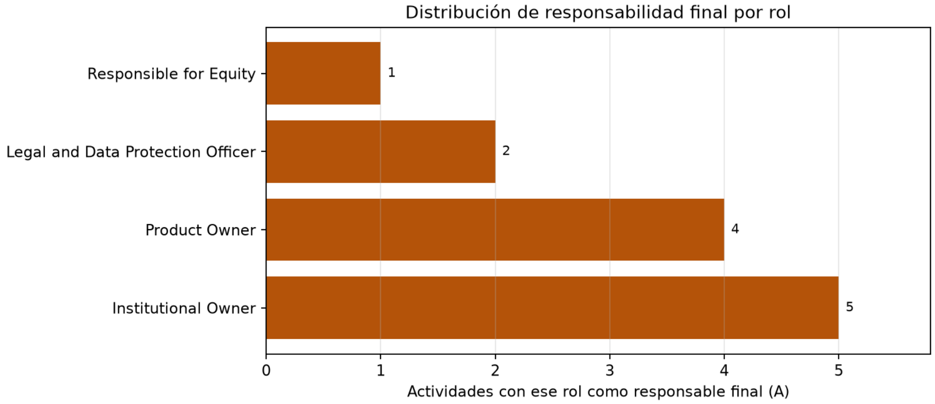

4. Monitoreo, runbook y simulacro

Puerta	Umbral	Medido	Resultado
recall	0.68	0.7174	correcta
brecha de recall (base)	0.16	0.1376	correcta
brecha de FPR	0.16	0.1250	correcta
latencia (ms/registro)	500	0.0160	correcta
tamaño del modelo (KB)	1024	3.5635	correcta
recall del peor grupo	0.7	0.6531	FALLA
brecha de recall en piloto	0.1	—	FALLA
soporte interseccional mínimo	15	8.0000	FALLA

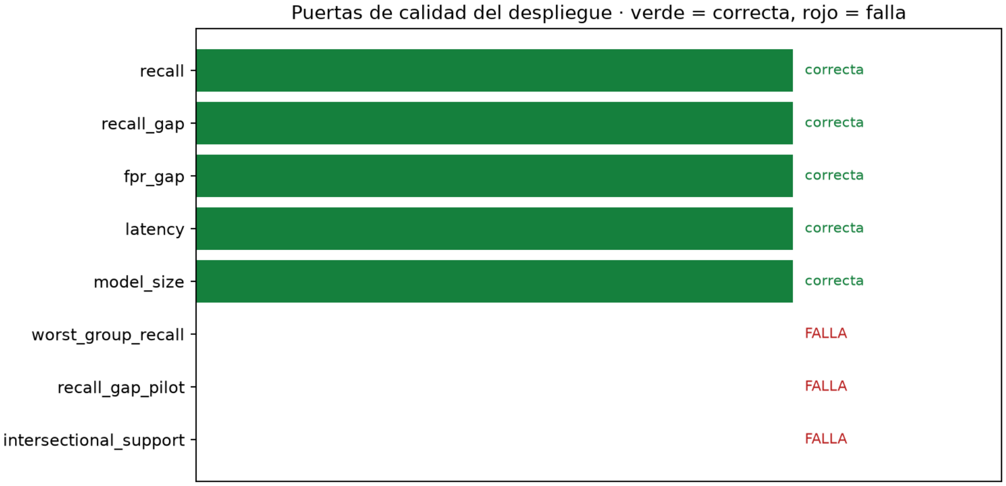

Simulacro de incidente. Señal: la brecha de recall (0,1376) supera la tolerancia de piloto (0,10); además el recall de G1 (0,6531) queda bajo 0,70 y hay celdas interseccionales con soporte insuficiente (n=8 y n=11). Contención: la decisión pasa a REVIEW, se congela la priorización automática y el equipo vuelve al baseline sin modelo con revisión humana de cada caso. Autoridad: ordena la contención el Institutional Owner; ejecuta el rollback el ML Engineer; valida la comunicación el Legal and Data Protection Officer. Evidencia preservada: logs, versión del modelo, métricas por grupo, reporte de incidente y commit exacto. Comunicación: interna en 24 h y a las personas afectadas por el canal de apelación en 72 h. Postmortem: ML Engineer, con cuatro acciones correctivas y fecha límite 2026-12-15 (`reports/lab13/INCIDENT_POSTMORTEM.md`).

5. Decisión final

LIMITAR. Con los umbrales por defecto del proyecto base (brecha de recall ≤ 0,16) el pipeline daría **GO**: recall 0,7174, brecha 0,1376, FPR 0,1250, latencia 0,016 ms y modelo de 3,56 KB cumplen las cinco puertas. Pero la tolerancia acordada en el LAB12 —brecha de recall ≤ 0,10 y recall del peor grupo ≥ 0,70— **no** se cumple, y con ella tres puertas fallan: la decisión del sistema es **REVIEW**. Una puerta fallida no se oculta: degrada el estado y obliga a una decisión humana documentada.

La brecha observada **no prueba discriminación causal**: el atributo sensible no entra al modelo y parte de la diferencia es la tasa base de positivos (G2 63,9 % frente a G1 49,6 %). Tampoco puede descartarse con una sola partición, una sola semilla, sin intervalos de confianza y con soporte interseccional insuficiente. Por eso la decisión se apoya en la tolerancia acordada y en el riesgo residual alto (R07: presión para decidir sin revisión humana), no en la métrica.

Condiciones para reactivar: (1) repetir la auditoría con un periodo posterior y con intervalos de confianza; (2) cuantificar el coste real del falso negativo para fijar la tolerancia con evidencia; (3) ampliar el soporte interseccional o retirar esas métricas del tablero. Mientras tanto: revisión humana obligatoria, baseline sin modelo como camino operativo seguro, simulacro y canal de apelación activos, y revisión trimestral (próxima: 2027-01-15).

Obligación legal, marco voluntario y recomendación ética. No hay una obligación legal verificable sobre un caso sintético, y esa ausencia se documenta en lugar de suplirse: el **NIST AI RMF 1.0** (marco voluntario) organiza el control —GOVERN, MAP, MEASURE, MANAGE— y la **recomendación ética** sostiene la decisión (baseline no predictivo, apelación, condiciones de retiro). Ninguna de las dos sustituye la revisión jurídica que cualquier uso con datos reales exigiría.

Uso responsable de IA. El asistente de IA (Kilo, modelo MiniMax-M3) apoyó la estructura del expediente, la redacción de las tarjetas y la corrección de dos scripts del proyecto base que no compilaban. Los **valores del análisis** —probabilidad e impacto de cada riesgo, umbrales de las puertas, tolerancia, roles del RACI y decisión— los decidió el estudiante con la evidencia del manual y de las ejecuciones; el asistente no inventó ninguna cifra ni referencia. Detalle en `docs/AI_USE_DECLARATION.md`.

Referencias. NIST, *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*, DOI 10.6028/NIST.AI.100-1 · OECD, *Recommendation of the Council on Artificial Intelligence*, DOI 10.1787/cc2e1d3e-en · Fairlearn Contributors, *Performing a Fairness Assessment* (documentación oficial).