Ejercicio 08 · Expediente de gobernanza y simulacro

INF-8239 Ciencia de Datos II (UASD) · Unidad 04 · Integración de LAB13

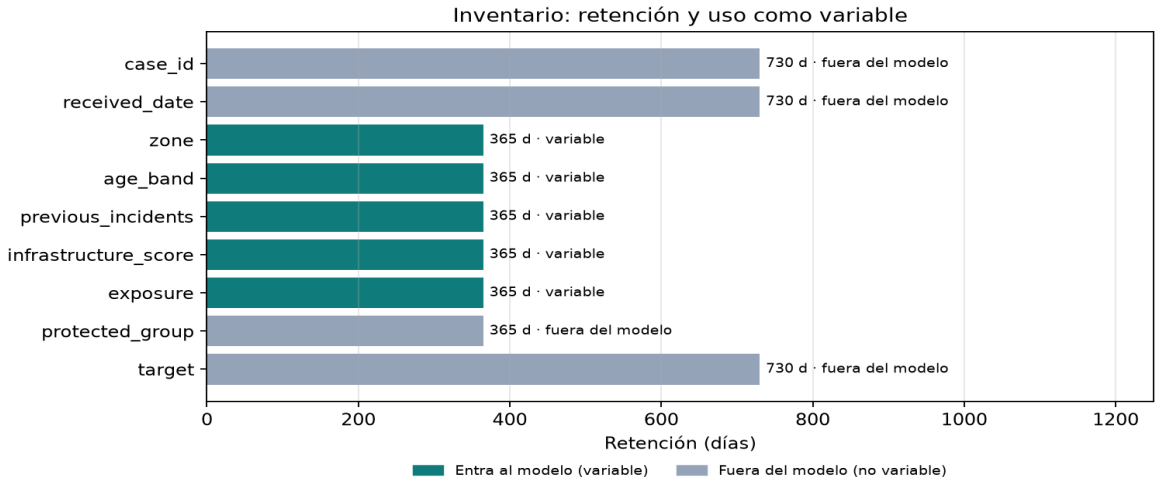
Estudiante	Edwing Perez
Profesor	Edwin Ramón José Nolasco
Repositorio	https://github.com/edvvdev/unidad04-08
Caso	Riesgo territorial SINTÉTICO (640 registros) · no representa personas ni estadísticas reales de RD
Decisión final	LIMITAR · DSS en modo REVIEW, revisión humana obligatoria, baseline sin modelo como camino seguro
Decisión del pipeline	REVIEW · puertas fallidas: worst_group_recall, recall_gap_pilot, intersectional_support

1. Inventario, minimización y retención

Todo campo declarado tiene origen, uso, condición de entrada al modelo, plazo de retención y justificación; las columnas de identificadores directos se rechazan **antes** de predecir.

Campo	Uso	¿Entra al modelo?	Retención (días)	Justificación
case_id	trazabilidad interna del caso sintetico…	no	730	identificador del registro sintetico; no conti…
received_date	corte temporal y deteccion de deriva…	no	730	fecha sintetica de recepcion; no se usa como v…
zone	variable predictora…	sí	365	contexto territorial sintetico, disponible al …
age_band	variable predictora y auditoria interseccional…	sí	365	banda de edad sintetica, disponible al predeci…
previous_incidents	variable predictora…	sí	365	historial de incidentes reportados…
infrastructure_score	variable predictora…	sí	365	indice sintetico de infraestructura…
exposure	variable predictora…	sí	365	exposicion sintetica al evento…
protected_group	auditoria de equidad por grupo; nunca entra al…	no	365	atributo sensible conservado solo para auditar…
target	etiqueta para entrenamiento y evaluacion…	no	730	etiqueta sintetica…

Minimización: case_id, received_date, protected_group, target quedan fuera del modelo por decisión explícita. Nunca permitidos: name, document_number, email, phone. Retención de artefactos: eventos operativos 180 días, logs de revisión 365 días, models y reports 730 días, registros de apelación 1095 días. Ejecución de la supresión: Data Engineer, con aprobación de Legal and Data Protection Officer.



2. Datasheet y Model Card trazables

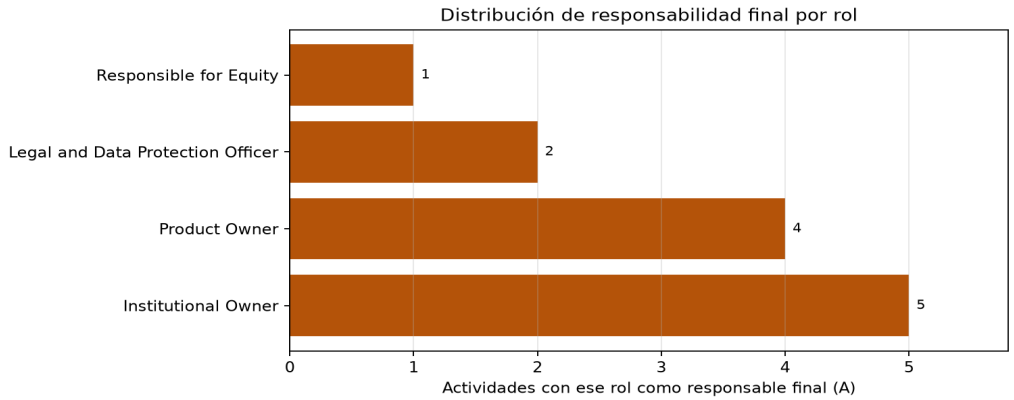
Documento	Contenido	Evidencia que respalda cada cifra
docs/DATASET_CARD.md	Procedencia, diccionario, auditoría, sesgos, usos prohibidos y corte temporal	reports/lab13/dataset_stats.json · reports/lab11/rmf_summary.json
docs/MODEL_CARD.md	Uso previsto y fuera de alcance, datos y partición, evaluación global y por subgrupo, evidencia Green AI, puertas de calidad, límites, supervisión y apelación, propietario y calendario de revisión	reports/lab12/logistic/* · reports/lab13/deployment_decision.json · reports/lab13/model_facts.json · configs/governance.yml
docs/INVENTARIO_Y_RETENCION.md	Inventario por campo, minimización, retención y supresión de la cola	configs/governance.yml · tests/test_governance.py · tests/test_privacy.py
docs/RUNBOOK.md	Detección, autoridad, contención, preservación de evidencia, comunicación, rollback y escalamiento	reports/lab13/INCIDENT_POSTMORTEM.md · reports/lab13/deployment_decision.json
reports/lab11/DECISION_RECORD.md	Evaluación de impacto, nueve riesgos priorizados, incertidumbre y condiciones de retiro	reports/lab11/risk_register_scored.csv · reports/lab11/rmf_summary.json
student_inputs/lab12_decision.yml	Daño priorizado, métrica principal, tolerancia, evidencia, limitaciones y recomendación	reports/lab12/logistic/* · reports/lab13/dataset_stats.json

La Model Card del Ejercicio 08 está **completa**: la genera `scripts/build_model_card.py` a partir de `reports/` y de `configs/governance.yml`, sin ninguna cifra escrita a mano. Tasa base de positivos por grupo (`reports/lab13/dataset_stats.json`): datos completos (640 registros) G1 49,7 % y G2 63,9 %; prueba temporal (160 registros) G1 48,5 % y G2 72,9 %.

3. RACI y traspaso entre roles

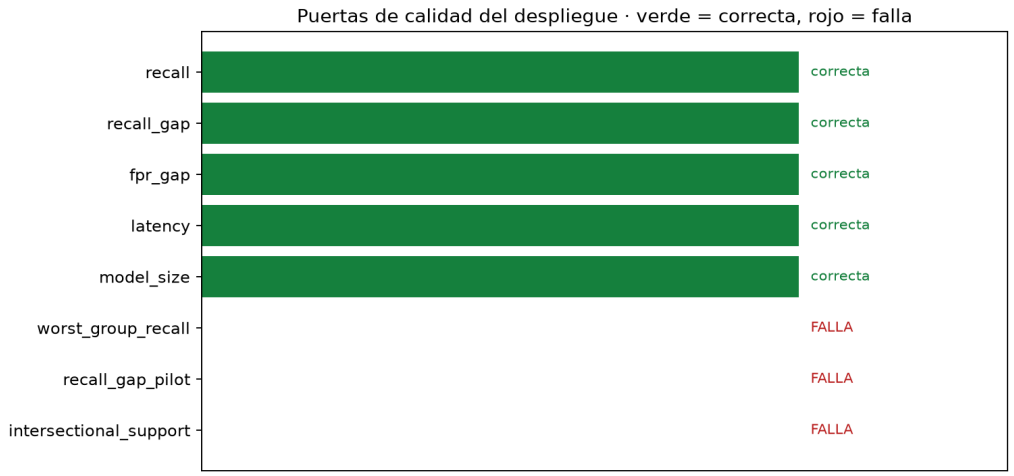
Cada actividad tiene **un solo responsable final (A)** y al menos un responsable de ejecución (R). El traspaso entre roles es explícito: quien entrega un artefacto lo entrega a un rol que puede rechazarlo. Verificación automática: `validate_raci` falla si una actividad no tiene A o R.

Actividad	R (ejecuta)	A (responde)	C (consulta)	I (informado)
Data quality and data contract	Data Engineer	Product Owner	Data Scientist	Affected representatives
Privacy review and prohibited columns	Data Engineer	Legal and Data Protection Officer	Data Scientist	Affected representatives
Model validation and reproducibility	Data Scientist	Product Owner	Data Engineer	Users
Fairness audit (global, group and intersectional)	Data Scientist	Responsible for Equity	Legal and Data Protection Officer	Affected representatives
Impact assessment and alternative comparison	Data Scientist	Institutional Owner	Responsible for Equity	Affected representatives
Deployment approval of the governed DSS	ML Engineer	Product Owner	Data Scientist	Users
Daily operation and human review of the queue	Operations Analyst	Product Owner	ML Engineer	Affected representatives
Monitoring, drift review and quarterly report	ML Engineer	Institutional Owner	Data Scientist	Users
Incident detection, containment and rollback	ML Engineer	Institutional Owner	Legal and Data Protection Officer	Affected representatives
Appeal handling of affected persons	Responsible for Equity	Institutional Owner	Operations Analyst	Affected representatives
Retention, deletion and expiry of evidence	Data Engineer	Legal and Data Protection Officer	Data Scientist	Affected representatives
Model revision, retirement or decommissioning	Data Scientist	Institutional Owner	Product Owner	Users



4. Monitoreo, runbook y simulacro

Puerta	Umbral	Medido	Resultado
recall	0,68	0,7174	correcta
brecha de recall (base)	0,16	0,1376	correcta
brecha de FPR	0,16	0,1250	correcta
latencia (ms/registro)	500	0,0160	correcta
tamaño del modelo (KB)	1024	3,56	correcta
recall del peor grupo	0,70	0,6531	FALLA
brecha de recall en piloto	0,10	0,1376	FALLA
soporte interseccional mínimo	15	8	FALLA



Simulacro de incidente. Señal: la brecha de recall (0,1376 supera la tolerancia de piloto (0,10); además el recall de G1 (0,6531) queda bajo el mínimo de 0,70 y hay 3 celdas interseccionales con soporte insuficiente (G2 | 45-59 (n=8), G2 | 18-29 (n=11), G2 | 30-44 (n=14); umbral 15). Contención: la decisión del pipeline pasa a REVIEW y se congela la priorización automática y el equipo vuelve al baseline sin modelo con revisión humana de cada caso. Autoridad: ordena la contención el Institutional Owner; ejecuta el rollback el ML Engineer; valida la comunicación el Legal and Data Protection Officer. Evidencia: logs de ejecución, versión del modelo, métricas por grupo e interseccionales y reporte de incidente; nada se elimina hasta el cierre. Comunicación: el Institutional Owner informa al equipo de operación y a los representantes de las personas afectadas por el canal de apelaciones. Acciones correctivas con responsable y fecha: `reports/lab13/INCIDENT_POSTMORTEM.md`.

5. Decisión final

Decisión documentada: LIMITAR. No hay despliegue autónomo: el DSS no se despliega de forma autónoma ni su ranking se usa como orden de ejecución. Con los umbrales por defecto del proyecto base (brecha de recall ≤ 0,16) el estado del evaluador sería GO: recall 0,7174, brecha 0,1376, FPR 0,1250, latencia 0,0160 ms y modelo 3,56 KB cumplen las cinco

puertas del base. Pero la tolerancia acordada en el LAB12 —brecha de recall ≤ 0,10 y recall del grupo con peor desempeño ≥ 0,70— **no** se cumple: el recall de G1 es 0,6531 y hay 3 celdas con soporte insuficiente. Una puerta fallida no se oculta: degrada el estado y obliga a una decisión humana documentada.

Estado del pipeline: REVIEW. Fallan tres puertas: `worst_group_recall` (0,6531 < 0,70), `recall_gap_pilot` (0,1376 > 0,10) e `intersectional_support` (8 < 15). REVIEW no es la decisión: es la señal de que la decisión la toma una persona, con la evidencia a la vista.

La brecha observada **no prueba discriminación causal**: el atributo sensible no entra al modelo y parte de la diferencia es la tasa base de positivos (G2 63,9 % frente a G1 49,7 %). Tampoco puede descartarse: con una sola partición, una sola semilla, sin intervalos de confianza y con soporte interseccional insuficiente, la decisión no se apoya en la métrica sino en la tolerancia acordada y en el riesgo residual alto (R07, presión para decidir sin revisión humana).

Escalamiento a STOP. Si la brecha de recall supera 0,15 o el recall del peor grupo baja de 0,60, el sistema se retira al baseline sin modelo. Los umbrales viven en `configs/governance.yml` → `escalation` y el procedimiento, en `docs/RUNBOOK.md` §5.

Condiciones para reactivar. (1) repetir la auditoría con un periodo posterior y con intervalos de confianza; (2) cuantificar el coste real del falso negativo para fijar la tolerancia con evidencia; (3) ampliar el soporte interseccional o retirar esas métricas del tablero. Mientras tanto: revisión humana obligatoria, baseline sin modelo como camino operativo seguro, simulacro de incidente y canal de apelación activos, y revisión de equidad trimestral (próxima: 2027-01-15).

6. Evidencia Green AI y control documental

Evidencia	Logística (elegida)	Árbol (descartado)
Tiempo de ajuste (s)	0,0191	0,0128
Latencia por registro (ms)	0,0160	no medida
Tamaño serializado (KB)	3,56	7,90
Parámetros entrenables	12 (11 coeficientes + 1 intercepto)	51 (nodos del árbol)

La logística se elige porque ocupa menos de la mitad de espacio que el árbol, con la misma utilidad global y brechas menores (`reports/lab12/comparativa_alternativas.csv`). Fuentes: `reports/lab13/model_facts.json` y `reports/lab13/deployment_decision.json`.

Obligación legal, marco voluntario y recomendación ética. En este caso sintético no hay una obligación legal específica que se pueda verificar (no hay datos personales ni decisiones reales), y esa ausencia se documenta en lugar de suplirse con el marco técnico: el **NIST AI RMF 1.0** (marco voluntario) organiza el control —GOVERN, MAP, MEASURE, MANAGE— y la **recomendación ética** (alternativa no predictiva, recurso de apelación, condición de retiro) sostiene la decisión. Ninguna de las dos sustituye a la revisión jurídica que cualquier uso con datos reales exigiría.

Uso responsable de IA. El asistente de IA (Kilo, modelo MiniMax-M3) apoyó la estructura de los artefactos, la redacción de las tarjetas y la corrección de dos scripts del proyecto base que no compilaban (`lab11_impact.py` y `simulate_incident.py`, por saltos de línea reales dentro de literales). Los **valores del análisis** —finalidad, interesados, probabilidad e impacto de cada riesgo, tolerancia, métrica principal y recomendación— los decidió el estudiante con la evidencia del manual y de las ejecuciones; el asistente no inventó ninguna cifra ni referencia. Detalle en `docs/AI_USE_DECLARATION.md`.

Referencias. NIST, *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*, DOI 10.6028/NIST.AI.100-1 · OECD, *Recommendation of the Council on Artificial Intelligence*, DOI 10.1787/cc2e1d3e-en · Fairlearn Contributors, *Performing a Fairness Assessment* (documentación oficial).